

Regression Analysis

- ← المحافظة مليانة concepts و تعريفات ممكنه نتسال فيهم في الشقوى أو MCQ
- ← أى relationship ما بين متغيرين ← عشانه أقدر أعمل العلاقة دي اصلا
- ← محتاجين نجمع data كلها ← نقدر بعدها نستخدم scatter plot ← وظيفته هو تحديد relationship

* Possible relationships

- ① Positive linear relationship variable ← متغير يزيد بناءً على زيادة المتغير التاني ↑
shown by a straight line with a positive slope
- ② Negative linear relationship variable ← متغير يزيد بناءً على نقصان المتغير التاني ↑
shown by a straight line with a negative slope
- ③ Nonlinear relationship ← أى تغير يحصل في متغير التاني مش هياش (مش هيعمل فيزيات)
- ④ NO obvious relationship ← حاجتين مالوش علاقة ببعض
← أى تغير يحصل مش بيؤدى لتغير واضح في العلاقة

* Regression line and predictions

↳ Pearson's correlation coefficient (r) is Significant indicating a meaningful linear relationship

↳ determined by a P-value below 0.05

← لم نحسبها بال SPSS مش manual

← الـ r اللى هو الـ Correlation Coeff. لما نقول انه Significant ده معناه ان العلاقة مفهومة ولها معنى $r = 0.1$ الـ P-value بتكون أقل من 0.05

→ The equation of the regression line, which is the data's line of best fit

← الهدف من الـ regression line هو ان نقدر نتنبأ على أى حاجة بناءً على الـ data كلها. الـ data هتقدر بعمل predict على ايه

Determining regression line when r is not significant and making predictions using it are meaningless

← فكرة الـ r انها not significant ← ده عايز أكبر وانه أعمل الـ regression line بناءً على حاجة غلط ← هعمل تنبؤ مالوش معنى
← يبقى عشان الـ regression line بياعدين انه أعمل تنبؤ صحيح وله معنى ومالية لازم الـ r تكون Significant

which means the correlation between two variables

is likely not due to chance

المنه
المهارة

Correlation symbol $\rightarrow$ In Sample : r
 $\rightarrow$ In Population : $\rho \rightarrow$ rho مش حرف ال P

* The Pearson correlation coefficient measures the linear relationship between two variables $\Rightarrow$ قيمة ال r تتراوح من -1 ل 1

- $\rightarrow r = 1 \rightarrow$ perfect positive linear relationship
- $\rightarrow r = 0 \rightarrow$ No linear relationship
- $\rightarrow r = -1 \rightarrow$ perfect negative linear relationship

Scatter plot with line of best fit

$\leftarrow$ لو جينا عملنا نقاط ال data $\leftarrow$ بنعمل خط في النص بالتقريب كدة يكون في

النص ما بين ال points $\leftarrow$ ده line مادي

$\leftarrow$ خط ايه هو ال line of best fit $\leftarrow$ هو افضل line نقدر نرسمه وسط

النقط فيه بحيث يكون اقرب ما يكون لكل النقط مش مجرد خط

يتوسط البيانات وخلاص $\leftarrow$ برحو وظيفته هو ال Prediction

مهمة $\rightarrow$ The line of best fit minimizes the sum of the squares of the vertical distances from each point to the line

في رسمة في سلايد 11 $\rightarrow$ ال المسافة ما بين ال data point و ال line نصه

Residuals

$\rightarrow$ The vertical distance between the actual value y and the Predicted value $\hat{y}$

$\leftarrow$ بنستخدم ال Residual عشان يساعدنا انه نحدد افضل خط قادر يوصف

العلاقة بين المتغيرات

Least squares method and predictions:

* The method of least squares minimizes the residuals and results in the least squares regression line

$\leftarrow$ زي ما قولنا انه ال line of best fit وظيفته هو التنبؤ للقيم $\leftarrow$ كلما النقط كانت

قريبة للخط أكثر كلما كان معناه انه التنبؤ احسن

* r is Positive $\rightarrow$ The line slopes upward from left to right

* r is negative $\rightarrow$ The line slopes downward left to right

Regression analysis $\rightarrow$ is a statistical technique for investigating and modeling the relationship between variables

$\rightarrow$ Application : engineering / The physical and chemical science

/ economics / management / life and biological sciences /

ALADIB the social sciences $\rightarrow$ ممكن ندرس ال فيهم في الشغوى

Simple linear regression model :

$$Y = \beta_0 + \beta_1 x + \epsilon$$

response variable dependent $\leftarrow Y$
 Slope Parameter $\leftarrow \beta_1$
 predictor variable Independent $\leftarrow x$
 Intercept Parameter $\leftarrow \beta_0$
 random error $\leftarrow \epsilon$
 الحسابي و الرموز مهمة جدًا
 $\rightarrow Y$ and $x \Rightarrow$ Variables
 $\rightarrow \beta_0$ and $\beta_1 \Rightarrow$ Parameters

$\rightarrow Y$ is called dependent variable or response variable
 $\rightarrow x$ is called independent variable or predictor variable
 $\ast Y, x$ are givens $\ast \beta_0, \beta_1$ are unknown
 لو في الامتحان قال β_0 determine the slope? ففقط

الدكتور قالت نلزم بطلوب السؤال ونبي عارفين الحسابي والرموز

$\ast \epsilon$: random error having a normal distribution with
 $M_\epsilon = 0$ and $\text{Var}(\epsilon) = \sigma_\epsilon^2 = \sigma^2 \rightarrow$ سؤال oral

$\ast x \rightarrow$ measured with negligible error

$\ast Y \rightarrow$ Dependent, random due to ϵ

$\ast \epsilon \rightarrow$ Random error with constant variance, $M = 0$
 and known as the homogeneous variance assumption

$$E(Y|x) = M_{Y|x} = E(\beta_0 + \beta_1 x + \epsilon) = \beta_0 + \beta_1 x$$

$$\text{Var}(Y|x) = \sigma_{Y|x}^2 = \text{Var}(\beta_0 + \beta_1 x + \epsilon) = \sigma^2$$

$\ast \ast M_{Y|x} = \beta_0 + \beta_1 x$ is a line of mean values

$\hookrightarrow$ Estimated regression line

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimated slope (rate of change in Y for a unit increase in x) $\leftarrow \hat{\beta}_1$
 Estimated intercept (y -value when $x = 0$) $\leftarrow \hat{\beta}_0$

Predicted

value of Y
 for given x

$$\hat{\beta}_0, \hat{\beta}_1$$

طبعًا عشان إجب ال Parameters اللي هم

$$Y = \beta_0 + \beta_1 x + \epsilon$$

هكون معتمدة على

$\ast$ Multiple linear regression model : $\rightarrow$ More than one predictor

ALADIB

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

الخطوة

* An important objective of regression analysis → to estimate the unknown parameters in the regression model
↳ Also called fitting the model to the data

← لما اشتغل على data لازم اتأكد انها اتجمعت مفيوت عشان
ميطلش ال model مليان Errors ويكون قابل للتطبيق

* Regression models serve various purposes including:

- 1 Describing data relationships
- 2 Estimating model parameters
- 3 Making Predictions and providing estimates
- 4 Facilitating control and decision making

ممكن
سؤال
oral

* Areas of use of regression analysis: oral ممكن يتج

- 1 Economics 2 Finance 3 Marketing 4 Health care
- 5 Social sciences 6 Environmental Science 7 Engineering
- 8 Quality control 9 Education 10 Sports Analytics

* Computers play a vital role in regression analysis by performing various tasks:

- 1 Data Handling
- 2 Model Estimation
- 3 Regression modeling
- 4 Visualization
- 5 Reporting and communication
- 6 Model adequacy

لما فيه أهم خطوة هي اختيار وتعديل ال model ← بعد ال best fit

- 7 The model-building
- 8 Model validation
- 9 Good regression computer program
- 10 Regression computer programs (ex: SPSS, Minitab, SAS and R)

لما الدكتور قالت شغلنا عليه ولازم نتدرب كثير عليه عشان
في الامتحان هيجي ال output ونسأل عليه شوية أسئلة

← في Examples كثير يفضل تقرأ منه السلايدر من صلايد 32 ل 66

← أهم حاجة في أي Example أو أي سؤال اتحدد مين ال dependent ومين ال independent

Important ✓✓

← حالة شاذة ✓✓

* A Predictor/response relationship that is not linear

* → A vertically separated point (outlier)

* → A horizontally separated point (Leverage Point)

الجزء ده هيجي في oral ← الاساس والمفاهيم مهمة

ممكن يجيب رسمة وفيها نقطة احده هي outlier ولا Leverage point

و احيد الاحداثيات بتاعتهم وهدهم outlier او Leverage احلا ولا لا

المنها صلايد 68 و 69 و 70 بتوضح شكل الرسمة

#SPSS → Statistical Package for the Social Sciences

→ Data view
→ Variable view
→ Syntax Error

الجابات التي
تظهر على الشاشة

← الدكتور نبهت انه نتدرب كثير على ال SPSS شاشة في الامتحان هيكونه في شاشة ال output وحين عليها أسئلة

* SPSS is ideal for handling large datasets with numerous variables
← بنستخدم فيه functions جاهزة ← built-in functions
← الجزء بتاع ال SPSS يتقرأ من السلايدز

Levels of Measurement → MCQ و oral مفهوم في

→ [1] Nominal Level → operations
Data are categorized without any order or quantitative value
← هي بيانات مش بيتعمل عليها أي operations ← بيكون زي الاسماء او labels
Examples: Gender - colors - Marital Status

→ [2] Ordinal Level: operations
Data have a meaningful order or ranking, but intervals are not equal

← هي بيانات مش بيتعمل عليها أي operations ← بيكون ranking
زي مثلاً Low, Medium, High ← دول ranking يعني تحت عنوان واحد (Levels)

[3] Scale Level (Interval / Ratio)

← أقدر أعمل عليها أي operations
Data are numerical with meaningful intervals or ratios
Examples: Temperature / Height / Age

← السلايدز التي بعد كدة خطوات استخدام ال SPSS ← تتقرأ من السلايدز
ونستعمل برنامج ال SPSS على أي data

* SPSS provides tools for creating a variety of charts such as bar charts, Histogram, Pie charts,

→ Histogram organizes a group of data points into user-specified ranges → used for showing the distribution of a single continuous variable

← الأجزاء بناءً على Histogram :

* Bins / Intervals → Range of data

* Frequency → The number of observations within each bin

* X-Axis → Represents the intervals of the variable

* Y-Axis → Represents the frequency of observations

→ Boxplot showing the distribution of data based on a five-number summary

↳ Used to visualize central tendency, spread, skewness and outliers

← الأجزاء بناءً على Boxplot :

* BOX → Represents the interquartile range (IQR)

* Median → Line inside the box showing the median value

* Whiskers → Lines extending from the box to the min and max values within 1.5 times the IQR

* Outliers → Points outside the whiskers indicating potential anomalies

Check for Data Errors :

↳ ① Missing values → Missing values

↳ ② Data consistency → data تكون متطابقة وصليقة

↳ ③ Duplicates → حذف أي قيم متكررة

↳ ④ Variable types

← موجود في سلايد 127 فيها dataset ممكن تجربها على برنامج SPSS