

## Regression Analysis

### # Least Squares Fit Properties

→ **Property ①** → The sum of the residuals in any regression model that contains an intercept  $\beta_0$  is always zero

$$\sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n e_i = 0$$

← يعني المجموع بتاع ال residuals أو ال errors بين في أي model موجود فيه  $\beta_0$

ببساطة ← أهم حاجة ال model ده يكون فيه  $\beta_0$

هو ممكن نلاق model فيهنوش  $\beta_0$  ؟ اه عادي جدًا

→ **Property ②** → The sum of the observed values  $y_i$  equals the sum of the fitted values  $\hat{y}_i$ , or

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$$

Exact value

← fitted or Predicted value

← يعني لو ال model الليندي كويس وابقى جيت ال best fit يبقى بالتالي

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$$

لازم ← ال Property ده تتحقق ←

→ **Property ③** → The least squares regression line always passes through the centroid, which is the point  $(\bar{x}, \bar{y})$  of the data

← النقطة المتوسطة في النقاط بتاعت data

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

← يعني لازم او دايما ال regression line هيمن بالنقطة  $(\bar{x}, \bar{y})$

→ **Property ④** → The sum of the residuals weighted by the corresponding value of the regressor variable always equals 0

$$\sum_{i=1}^n x_i e_i = 0$$

← ده معناه انه ال residuals غير مرتبطة (uncorrelated) بال Independent variable

الـ  $x$  هو

→ **Property ⑤** → The sum of the residuals weighted by the corresponding fitted value always equals zero

$$\sum_{i=1}^n \hat{y}_i e_i = 0$$

← ال Property ده بتأكدني انه القيم اللال ال model بيعملها predict  $(\hat{y})$  معتمدة على ال errors

→ **Property ⑥** → The regression coefficients  $\beta_0$  and  $\beta_1$  are estimated using the least squares method to minimize the sum of sq. resid.

→ The fitted values  $\hat{y}_i$  are predicted values for the dependent variable

← نفس الكلام بتاع الحاضرة الـ فانت ← Parameters  $\beta_0, \beta_1$  بيكونوا least squ. unknowns وعشان اعرفهم بعل Estimation بطريقة

→ **Property ⑦** → The residuals represent the diff. between the observed and fitted values of  $y$ , showing how well the model fits the data # oral or MCQ

Residuals =  $y_i - \hat{y}_i$  ← تعتبر ال property ديه هي تعريف ال residuals

→ **Property ⑧** → If the model is correctly specified and assump. are met, the least squares estimator is (BLUE) → لوال model كويس  
Best Linear Unbiased Estimator

# Residual sum of squares ( $SS_{Res}$ ) # إشارات

Error ← Residuals ← sum of square ال عايزين نجيب ال

→  $SS_{Res} = \sum_{i=1}^n e_i^2 \Rightarrow e_i = y_i - \hat{y}_i$

$SS_{Res} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  ,  $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$

$SS_{Res} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2$

$SS_{Res} = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$  ,  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  ← هندخل السالب جوة

$SS_{Res} = \sum_{i=1}^n (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i)^2 = \sum_{i=1}^n (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)^2$

← من ال 2 terms دول ال هم  $\hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i$  هافد  $-\hat{\beta}_1$

$SS_{Res} = \sum_{i=1}^n [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]^2$  ← كعامل مشترك

$= \sum_{i=1}^n [(y_i - \bar{y}) - (x_i - \bar{x}) \hat{\beta}_1]^2$  ← ممكن باش حاجة يقتر فطبتها بحيث تكون نفس الشكل

اللي الدكتور كاتباه في السلايدر ← الخطوة الجاية هي فك ال bracket

$(x - y)^2$  : formula لهذا ال bracket  
 $\hookrightarrow (x^2 - 2xy + y^2)$

هناك ال bracket

$$SS_{Res} = \sum_{i=1}^n [(y_i - \bar{y}) - (x_i - \bar{x})\hat{\beta}_1]^2$$

عادى  
 في الاول في نفسه و الثاني في نفسه و الاول في الثاني في 2

$$SS_{Res} = \sum_{i=1}^n [(y_i - \bar{y})^2 - 2\hat{\beta}_1 (y_i - \bar{y})(x_i - \bar{x}) + (x_i - \bar{x})^2 \hat{\beta}_1^2]$$

← هتوزع علامة ال  $\sum$  على كل term و اى ثابت تطلع برة ال  $\sum$

$$SS_{Res} = \sum_{i=1}^n (y_i - \bar{y})^2 - 2\hat{\beta}_1 \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) + \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2$$

← بعدين هنفك ال و نضربها في

و مرة نفسك  $\bar{y}$  و نضربها في  $-2\hat{\beta}_1 \sum_{i=1}^n (x_i - \bar{x})$  ← ناخذ بالنا ان ال

عبارة مع ثابت بالتالي هتخرج برة ال  $\sum$

$$SS_{Res} = \sum_{i=1}^n (y_i - \bar{y})^2 - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + 2\hat{\beta}_1 \bar{y} \sum_{i=1}^n (x_i - \bar{x}) + \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2$$

← نركز على  $\sum_{i=1}^n (x_i - \bar{x})^2 \leftarrow S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$  ← هنعوض عنده ب  $S_{xx}$

$$SS_{Res} = \sum_{i=1}^n (y_i - \bar{y})^2 - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + 2\hat{\beta}_1 \bar{y} \sum_{i=1}^n (x_i - \bar{x}) + \hat{\beta}_1^2 S_{xx}$$

← المحاضرة اللي فاتت في جز unbiased estimator

قولنا ان  $\sum_{i=1}^n (x_i - \bar{x})$  يساوي صفر = حاجة ثابتة

فذلك

$$SS_{Res} = \sum_{i=1}^n (y_i^2 - 2\bar{y}y_i + \bar{y}^2) - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + 2\hat{\beta}_1 \bar{y} \times 0 + \hat{\beta}_1^2 S_{xx}$$

$$SS_{Res} = \sum_{i=1}^n y_i^2 - 2\bar{y} \sum_{i=1}^n y_i + \sum_{i=1}^n \bar{y}^2 - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + \hat{\beta}_1^2 S_{xx}$$

ال  $\sum_{i=1}^n y_i = n\bar{y}$  ←  $\sum_{i=1}^n \bar{y}^2 = n\bar{y}^2$  ← بيساوي n في الثابت

$$SS_{Res} = \sum_{i=1}^n y_i^2 - 2\bar{y} \cdot n\bar{y} + n\bar{y}^2 - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + \hat{\beta}_1^2 S_{xx}$$

$$SS_{Res} = \sum_{i=1}^n y_i^2 - 2n(\bar{y}^2) + n\bar{y}^2 - 2\hat{\beta}_1 \sum_{i=1}^n y_i (x_i - \bar{x}) + \hat{\beta}_1^2 S_{xx}$$

←  $-2x + x$  كدة  $S_{xy}$

$$SS_{Res} = \sum_{i=1}^n y_i^2 - n\bar{y}^2 - 2\hat{\beta}_1 S_{xy} + \frac{S_{xy}}{S_{xx}} \cdot \frac{S_{xy}}{S_{xx}} \cdot S_{xx}$$

$$SS_{Res} = \sum_{i=1}^n y_i^2 - n\bar{y}^2 - 2\hat{\beta}_1 S_{xy} + \hat{\beta}_1 S_{xy}$$

نفس القصة  
 $-2xy + xy$   
 $= -x$

ALADIB

كل الإثباتات التي فات أو أغلبه معتمد على التقويين ✓

## # Total Sum of Squares $SS_T \rightarrow$ إثباتات

نأخذ بين  $SS_T$  و  $SS_{Res}$  فرق بين  $SS_T$  و  $SS_{Res}$

Total sum of square  $\Rightarrow \sum_{i=1}^n (y_i - \bar{y})^2$  المسألة بتبدأ

Residual sum of square  $\Rightarrow \sum_{i=1}^n (y_i - \hat{y}_i)^2$  المسألة بتبدأ

\*  $y_i - \hat{y}_i$  ← Residual sum of sq في حالة

$y_i - \bar{y}$  ← Total sum of sq. في حالة ال

الإثبات:

$SS_T = \sum_{i=1}^n (y_i - \bar{y})^2$  → هناك ال bracket عادي

$SS_T = \sum_{i=1}^n (y_i^2 - 2\bar{y}y_i + \bar{y}^2)$  → لنوزع ال

$SS_T = \sum_{i=1}^n y_i^2 - 2\bar{y} \sum_{i=1}^n y_i + \sum_{i=1}^n \bar{y}^2$  → أي ثابت جوة ال  $\sum_{i=1}^n \bar{y}^2 = n\bar{y}^2$  بيساوي الثابت  $n \times$

$SS_T = \sum_{i=1}^n y_i^2 - 2\bar{y} \cdot n\bar{y} + n\bar{y}^2$

$SS_T = \sum_{i=1}^n y_i^2 - 2n\bar{y}^2 + n\bar{y}^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2$  #

\* العلاقة الرياضية التي تربط بين  $SS_T$  و  $SS_{Res}$ :

$SS_{Res} = SS_T - \hat{\beta}_1 S_{xy}$

\* The residual sum of squares has  $df = n - 2$

لأنه في ال model ده معدهوشت غير 2 parameter  $\beta_0, \beta_1$

\* The expected value of  $SS_{Res}$ :  $E(SS_{Res}) = (n-2)\sigma^2$

\* An unbiased estimator of  $\sigma^2$ :  $\hat{\sigma}^2 = \frac{SS_{Res}}{n-2} = MS_{Res}$   
mean square Error

\*  $MS_{Res} \Rightarrow$  mean square Error or residual mean square

$MS_{Res} = \frac{SS_{Res}}{n-2} = \frac{SS_{Res}}{df}$

## # Hypothesis testing on the slope and intercept

نحتاج فترات الثقة على model parameters

\* Errors are normally distributed

\* Errors are independently distributed with mean 0 and variance  $\sigma^2$

→ Use of t tests :- To test the hypothesis that the slope equals


constant, say  $\beta_{10}$  :

$$H_0: \beta_1 = \beta_{10}$$

$$H_1: \beta_1 \neq \beta_{10}$$

القيمة ديه تكون given

في الامتحان ✓



These hypothesis specify a two-sided alter.

The errors  $\epsilon_i$  are assumed to be  $N(0, \sigma^2)$

The observations  $y_i$  follow  $N(\beta_0 + \beta_1 x_i, \sigma^2)$

\* The slope estimator  $\hat{\beta}_1$  is a linear combination of the observation so it is normally distributed with

1. Mean  $\Rightarrow \beta_1$

2. Variance  $\Rightarrow \frac{\sigma^2}{S_{xx}}$

3. Test statistic :  $Z_0 = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\sigma^2}{S_{xx}}}}$

\*  $MS_{Res}$  is unbiased estimator of  $\sigma^2$  \*  $MS_{Res}, \hat{\beta}_1 \Rightarrow$  independent

\*  $(n-2) \frac{MS_{Res}}{\sigma^2} \Rightarrow$  Chi-square تتبع توزيع الـ

→ t-statistic Formula :  $t_0 = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{MS_{Res}}{S_{xx}}}}$

الخطوات

→ Testing Procedure :

① computes  $t_0$  from the formula

② compares the observed value of  $t_0$

و بنجيب  $t_{\alpha/2, n-2}$  ديه قيمة جدولية  $\leftarrow$  يكونه given في الامتحان

③ Rejects the null hypothesis if  $|t_0| > t_{\alpha/2, n-2}$

يرفض الـ  $H_0$  لو الـ  $t_0$  حلت اكبر من قيمة الجدول

والـ  $t_0$  بنجيبها من القانون

→ Standard error of the slope  $se(\hat{\beta}_1) = \sqrt{\frac{MS_{Res}}{S_{xx}}}$

→  $t_0$  Test statistic  $t_0 = \frac{\hat{\beta}_1 - \beta_1}{se(\hat{\beta}_1)}$

### # Testing Hypothesis about the intercept

[1]  $H_0: \beta_0 = \beta_{00}$  given قِمة  
 $H_1: \beta_0 \neq \beta_{00}$

نفس الكلام  
في  $\beta_1$  بس هنا  
بدل  $\beta_1$   
لنقول  $\beta_0$

[2] Test statistic:  $t_0 = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{MS_{Res} \left( \frac{1}{n} + \frac{\bar{x}^2}{S} \right)}} = \frac{\hat{\beta}_0 - \beta_{00}}{se(\hat{\beta}_0)}$

[3] Reject  $H_0$  if:  $|t_0| > t_{\alpha/2, n-2}$

### \* Hypothesis for significance of regression

→ Special case of the hypothesis:  $H_0: \beta_1 = 0$   $H_1: \beta_1 \neq 0$

↳ These hypothesis relate to the significance of regression

\* Failing to reject  $H_0 \Rightarrow$  there is no linear relationship between  $x$  and  $y$

↳ The test Procedure for  $H_0: \beta_1 = 0$ :  $t_0 = \frac{\hat{\beta}_1}{se(\hat{\beta}_1)}$

Reject  $H_0$ : if  $|t_0| > t_{\alpha/2, n-2}$

otherwise → Fail to reject  $H_0$

Fail to reject هي لو قولت SS, Accept

ال decision التي باخده بيكونه بناءً على ال sample التي خدتها

هيقول Accept = لو انا أخذت ال population كلها

Fail to reject = انا أخذت sample و درستها

\* Failing to reject means no linear relationship bet.  $x$  and  $y$

\* Rejecting  $H_0 \Rightarrow$  مش معناه انه مجرد برفض ال  $H_0$  وخلاص  
ده ممكنه يبقى مؤشر انه ال model محتاج يتعدل

الخطأ النوع الثاني  
لازم يقول في الامتحان ال  $\alpha$  بكلام ولو مش موجودة في الامتحان  $\alpha = 0.05$  باخذها